

Détection non supervisée de fraude automobile

Isolation Forest appliqué à la base CarClaims

Projet de recherche • M2 Actuariat • ISFA / ENSEA

15 420

déclarations analysées

5,99 %

taux de fraude

0,52

ROC-AUC
Isolation Forest

1,39×

meilleur lift@5 %
(LOF)

Problématique. Peut-on repérer des déclarations frauduleuses sans apprendre leurs étiquettes, uniquement parce qu'elles présentent des configurations rares et faciles à isoler ? Le travail reproduit la logique d'Isolation Forest, construit une chaîne de préparation sans fuite et évalue le score d'anomalie comme outil de priorisation des enquêtes.

Membres

ROBGO Hamid • DIAKITE Sekou Fadel

KOFFI Daphne • KANTE Karifala

Encadrant

François Hu — Milliman R&D, ISFA

Article

Liu, Ting & Zhou (2012), *Isolation-Based Anomaly Detection*

Données

Vehicle Insurance Claim Fraud (CarClaims), 15 420 dossiers

Date

13 juillet 2026

1. Problématique et ancrage scientifique

1.1 De la fraude à l'anomalie

La fraude est rare, évolutive et imparfaitement observée. Les fraudeurs adaptent leurs comportements aux dispositifs de contrôle, tandis que les étiquettes disponibles reflètent souvent les dossiers effectivement enquêtés plutôt que toute la fraude réelle [Bolton and Hand, 2002]. En assurance automobile, les travaux historiques comparent surtout des classifieurs supervisés alimentés par des indicateurs métier et des appréciations d'experts [Viaene et al., 2002].

Une anomalie désigne une observation qui s'écarte du comportement attendu [Chandola et al., 2009]. Cette définition ne se confond pas avec la fraude : un dossier légitime peut être atypique et une fraude organisée peut ressembler aux dossiers ordinaires. Nous testons donc une hypothèse précise : **les fraudes de CarClaims sont-elles plus isolables que les non-fraudes dans l'espace des variables disponibles ?**

Positionnement opérationnel

Le score d'anomalie sert à ordonner une file d'investigation. Il ne constitue ni une preuve, ni une décision automatique de rejet. Une performance utile doit concentrer les fraudes parmi les quelques dossiers qu'un service de contrôle peut effectivement examiner.

1.2 Pourquoi Isolation Forest ?

Les approches par distance ou densité cherchent à caractériser les régions normales avant d'identifier leurs écarts. Isolation Forest adopte l'idée inverse : les anomalies sont peu nombreuses et différentes, donc des partitions aléatoires devraient les isoler en moins de coupures [Liu et al., 2008, 2012]. Le modèle offre trois avantages pour cette étude :

- apprentissage non supervisé, cohérent avec la rareté des étiquettes fiables ;
- sous-échantillonnage natif, coût de calcul limité et moindre effet de masquage ;
- score continu directement mobilisable pour classer les dossiers.

1.3 Littérature connexe et limites connues

LOF compare la densité locale d'une observation à celle de ses voisins et cible des anomalies locales [Breunig et al., 2000]. One-Class SVM estime une frontière entourant la masse principale des données [Schölkopf et al., 2001]. Ces deux méthodes forment des baselines complémentaires à l'isolation aléatoire.

La littérature souligne trois difficultés pertinentes ici. En grande dimension, distances, voisinages et volumes deviennent moins discriminants [Zimek et al., 2012]. Les anomalies groupées peuvent ne pas être isolées rapidement ; SCiForest adapte le mécanisme de coupe à ce cas [Liu et al., 2010]. Enfin, les coupes parallèles aux axes d'iForest peuvent produire des artefacts géométriques ; Extended Isolation Forest utilise des hyperplans aléatoires [Hariri et al., 2021].


1.4 Contributions du projet

1. une EDA auditable reliant qualité, déséquilibre, cardinalités et signaux descriptifs ;
2. un feature engineering ajusté uniquement sur le train ;
3. une sélection sur validation séparée du test final ;
4. une évaluation globale (ROC/PR) et opérationnelle (lift aux premiers pourcentages) ;
5. une interprétation honnête des résultats négatifs et de leurs implications actuarielles.

2. Méthode : isoler plutôt que modéliser la normalité

2.1 Construction d'un arbre d'isolation

À chaque nœud, l'algorithme choisit aléatoirement une variable q , puis un seuil p uniformément entre son minimum et son maximum observés. Les observations sont séparées selon $x_q < p$. La récursion s'arrête lorsqu'une observation est seule, que toutes les valeurs sont identiques ou que la hauteur limite est atteinte.



Un arbre unique est instable ; la forêt moyenne les longueurs de chemin. Pour un sous-échantillon de taille ψ , la longueur attendue est normalisée par

$$c(\psi) = 2H_{\psi-1} - \frac{2(\psi-1)}{\psi}, \quad s(x, \psi) = 2^{-E[h(x)]/c(\psi)}.$$

Si $s \approx 1$, l'observation est fortement anormale ; si $s < 0,5$, elle ressemble à la masse normale ; autour de 0,5, aucune séparation nette n'apparaît [Liu et al., 2012].

2.2 Rôle des hyperparamètres

Paramètre	Valeurs	Effet attendu
Arbres t	100, 200	stabilise le score, à rendement décroissant
Sous-éch. ψ	64, 128, 256, 512	règle la granularité et la profondeur des arbres
Variables	toutes	pertinentes après retrait des identifiants
Contamination	non utilisée	le classement est évalué sans imposer de taux
Graines	3 répétitions	mesure la sensibilité à l'aléa de construction

2.3 Ce que le score apprend - et n'apprend pas

Le modèle n'apprend pas la classe fraude. Il apprend une géométrie de rareté créée par la représentation des variables. Une catégorie rare peut donc sembler anormale même si elle n'est pas risquée. À l'inverse, une fraude utilisant une configuration commune peut recevoir un score faible. L'encodage est ainsi une composante du modèle, et pas une simple opération technique.

Conséquence méthodologique. Toute statistique d'encodage, de centrage ou d'échelle est estimée sur le train puis appliquée sans réajustement à la validation et au test. Les étiquettes servent à comparer les classements, jamais à construire les détecteurs.

2.4 Complexité et reproductibilité

La construction bénéficie du sous-échantillonnage : les arbres restent courts et le coût augmente approximativement de manière linéaire avec le nombre d'arbres et la taille des données scorées. Les graines, partitions et hyperparamètres sont fixés dans le notebook de modélisation. Les artefacts finaux sont produits dans `data/sorties/`.

3. Données, qualité et analyse exploratoire

3.1 Base CarClaims

Le fichier `fraud_oracle.csv` contient **15 420 déclarations**, **32 prédicteurs** et la cible `FraudFound_P`. Les 923 fraudes représentent 5,99% des dossiers. L’audit initial ne détecte ni valeur manquante explicite ni doublon exact. Cette propreté apparente n’exclut pas des modalités textuelles sentinelles ni des incohérences métier.

Famille	Variables représentatives	Vigilance / décision
Identifiants	PolicyNumber, RepNumber	PolicyNumber exclu ; unicité et fuite potentielle catégories, ordre cyclique à représenter explicitement qualité des âges et contrôle par sous-groupe modalités ordinales ou intervalles textuels signaux métier descriptifs, non causaux classes ordonnées et modalités rares
Calendrier	Month, DayOfWeek, Year	
Assuré	Age, Sex, MaritalStatus	
Contrat/véhicule	PolicyType, VehiclePrice, AgeOfVehicle	
Circonstances	Fault, PoliceReportFiled, WitnessPresent	
Historique	PastNumberOfClaims, NumberOfSupplements	

3.2 Résultats structurants de l’EDA




FIGURE 1 – Déséquilibre de la cible et hétérogénéité descriptive selon la responsabilité déclarée.

Le premier graphique confirme qu’une accuracy brute serait trompeuse : prédire systématiquement « non-fraude » donnerait déjà 94,01%. Le second montre une association descriptive forte avec `Fault` : 7,9% de fraude lorsque le titulaire est déclaré responsable, contre 0,9% pour un tiers. Cette différence ne prouve ni causalité ni stabilité future, mais suggère des interactions utiles.

L’EDA complète du notebook analyse distributions, cardinalités, modalités rares, cohérence des âges, saisonnalité, taux par catégorie, croisements et associations. Elle conduit aux choix suivants :

- conserver les catégories nominales sans leur imposer un ordre arbitraire ;
- créer des représentations cycliques pour les variables calendaires lorsque pertinent ;
- surveiller les modalités à faible effectif avant toute interprétation de taux ;
- retirer l’identifiant de police et éviter que le modèle n’isole seulement des identités ;
- préférer une représentation compacte pour limiter la dilution en grande dimension.

3.3 Feature engineering retenu

Les catégories sont encodées par leur fréquence observée dans le train. Les variables numériques sont standardisées avec les paramètres du train. Cette solution limite le nombre de dimensions par rapport au one-hot et accepte les modalités inconnues via une règle explicite. Son coût est une perte d’information : deux catégories de même fréquence deviennent indiscernables. Les sorties finales contiennent les matrices train/test mises à l’échelle et leurs étiquettes séparées.

4. Protocole expérimental et résultats

4.1 Séparation, sélection et évaluation

Les données sont divisées en train, validation et test avec stratification afin de conserver une prévalence comparable. La cible n'entre ni dans les transformations ni dans l'ajustement des détecteurs. La grille iForest est comparée sur validation avec trois graines ; la configuration choisie est $\psi = 128$ et 100 arbres. Le test n'est consulté qu'après ce choix.



Métriques. ROC-AUC évalue le classement global. PR-AUC est plus sensible à la classe rare ; son niveau aléatoire correspond ici à la prévalence, soit environ 0,0599. Le lift@ k compare le taux de fraude dans les $k\%$ dossiers les mieux scorés au taux global. Un lift de 1 signifie que la sélection ne fait pas mieux que le hasard.

Méthode	ROC-AUC	PR-AUC	Lift@5%	Lift@10%
Isolation Forest	0,5207	0,0675	0,8692	1,0403
LOF	0,5537	0,0729	1,3907	1,4738
One-Class SVM	0,5405	0,0681	1,0430	1,2137
Aléatoire	0,5000	0,0599	1,0000	1,0000




FIGURE 2 – Performances hors échantillon. Les lignes pointillées matérialisent le niveau aléatoire.

4.2 Lecture des performances

LOF obtient le meilleur classement global et la meilleure concentration aux seuils étudiés. Dans le top 5%, son lift de 1,39 signifie que cette petite file contient environ 39% plus de fraudes qu'une sélection aléatoire de même taille. Ce gain reste modeste et doit être confronté au coût d'une enquête et au nombre de faux positifs.

iForest dépasse légèrement le hasard en ROC-AUC et PR-AUC, mais son lift@5% est inférieur à 1. Il ordonne donc mal l'extrême tête de liste, précisément là où une cellule antifraude attend le plus de valeur. One-Class SVM est intermédiaire. La faible amplitude générale indique que **la fraude n'est pas principalement une anomalie globale dans cette représentation.**

Résultat central. L'expérience ne valide pas Isolation Forest comme filtre autonome de fraude sur CarClaims. Ce résultat négatif est scientifique : il distingue la capacité à détecter la rareté de la capacité à identifier la fraude.

5. Discussion, conclusion et perspectives

5.1 Interprétation actuarielle

Les variables disponibles décrivent le contrat, le véhicule et le traitement du dossier, mais probablement de façon incomplète le mécanisme frauduleux. Une fraude peut être comportementalement subtile, collective ou construite dans une région dense. Inversement, les configurations rares légitimes sont facilement isolées. Le modèle peut donc servir de signal complémentaire de nouveauté, pas de preuve.

Pour une utilisation réelle, le seuil devrait être défini par le budget d'audit et une matrice de coûts : coût d'enquête, gain récupérable, préjudice d'un faux positif et coût d'une fraude manquée. Les métriques de classement doivent être complétées par précision@ k , rappel@ k , montant détecté@ k et stabilité par segment.

5.2 Limites et plan d'amélioration

Limites

- documentation incomplète du processus d'étiquetage ;
- possible biais de sélection des dossiers enquêtés ;
- découpage stratifié, mais non strictement temporel ;
- encodage fréquentiel qui compresse les catégories ;
- absence d'intervalles de confiance et de fonction de coût ;
- une seule base publique, donc généralisation non établie.

Priorités

1. validation temporelle et bootstrap à 95% ;
2. variables de délai et incohérences métier ;
3. comparaison one-hot, fréquence et embeddings ;
4. EIF, SCiForest et ensembles de détecteurs ;
5. évaluation par budget d'audit et par sous-groupe ;
6. approche semi-supervisée combinant score et expertise.

Conclusion générale. Isolation Forest fournit un score non supervisé reproductible, rapide et conceptuellement clair. Sur CarClaims, ce score n'identifie toutefois que faiblement les fraudes et échoue à les concentrer dans le top 5%. LOF constitue la meilleure baseline testée, sans justifier une automatisation. Le dispositif pertinent est hybride : anomalies, règles métier, modèle supervisé lorsque les labels sont fiables, et décision humaine.

Références

- R. J. Bolton and D. J. Hand. Statistical fraud detection : A review. *Statistical Science*, 17(3) :235–255, 2002. doi : 10.1214/ss/1042727940.
- M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander. LOF : Identifying density-based local outliers. In *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pages 93–104, 2000. doi : 10.1145/335191.335388.
- V. Chandola, A. Banerjee, and V. Kumar. Anomaly detection : A survey. *ACM Computing Surveys*, 41(3) :1–58, 2009. doi : 10.1145/1541880.1541882.
- S. Hariri, M. Carrasco Kind, and R. J. Brunner. Extended isolation forest. *IEEE Transactions on Knowledge and Data Engineering*, 33(4) :1479–1489, 2021. doi : 10.1109/TKDE.2019.2947676.
- F. T. Liu, K. M. Ting, and Z.-H. Zhou. Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining*, pages 413–422, 2008. doi : 10.1109/ICDM.2008.17.
- F. T. Liu, K. M. Ting, and Z.-H. Zhou. On detecting clustered anomalies using sciforest. In *Machine Learning and Knowledge Discovery in Databases*, pages 274–290, 2010. doi : 10.1007/978-3-642-15883-4_18.
- F. T. Liu, K. M. Ting, and Z.-H. Zhou. Isolation-based anomaly detection. *ACM Transactions on Knowledge Discovery from Data*, 6(1) : 1–39, 2012. doi : 10.1145/2133360.2133363.
- B. Schölkopf, J. C. Platt, J. Shawe-Taylor, A. J. Smola, and R. C. Williamson. Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7) :1443–1471, 2001. doi : 10.1162/089976601750264965.
- S. Viaene, R. A. Derrig, B. Baesens, and G. Dedene. A comparison of state-of-the-art classification techniques for expert automobile insurance claim fraud detection. *Journal of Risk and Insurance*, 69(3) :373–421, 2002. doi : 10.1111/1539-6975.00023.
- A. Zimek, E. Schubert, and H.-P. Kriegel. A survey on unsupervised outlier detection in high-dimensional numerical data. *Statistical Analysis and Data Mining*, 5(5) :363–387, 2012. doi : 10.1002/sam.11161.